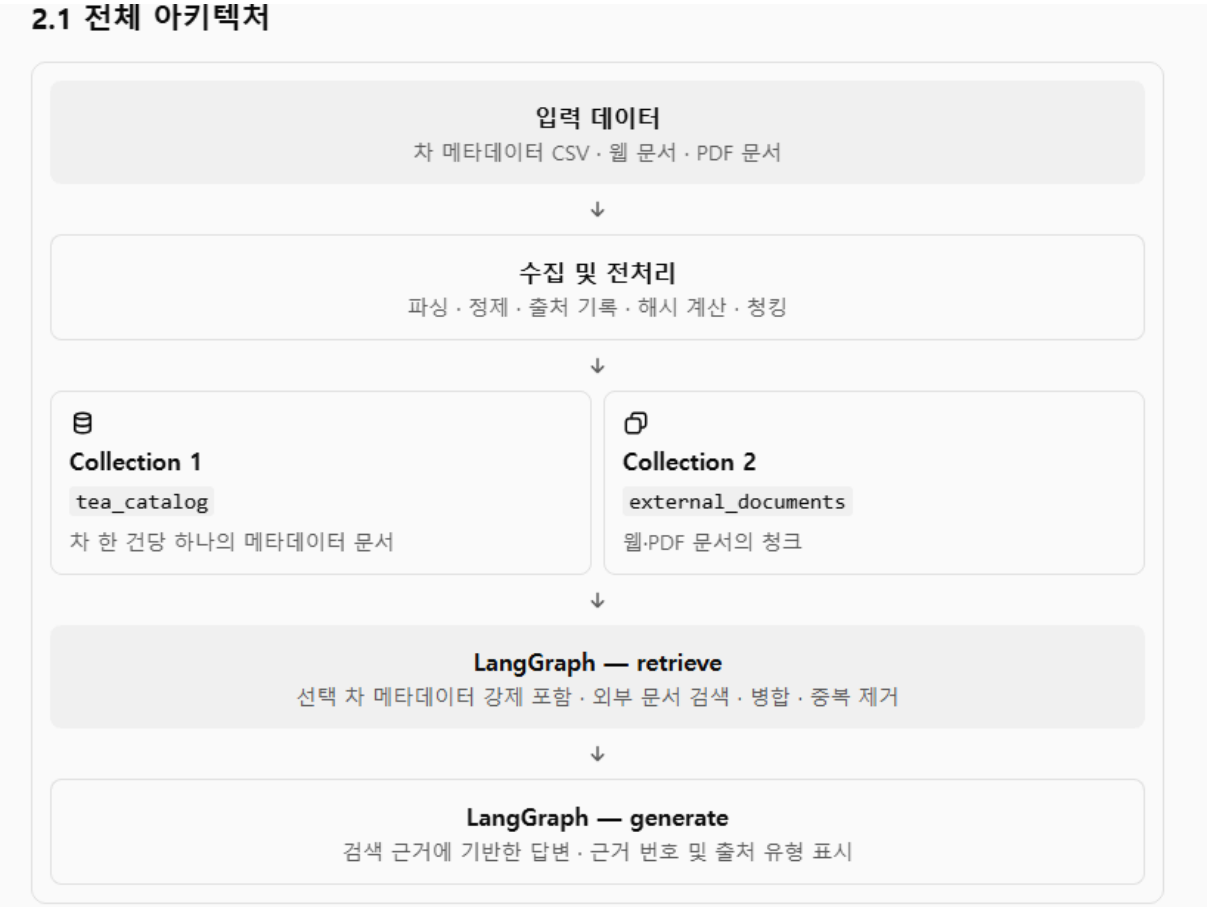
설계

날짜	2026년 10월 23일

2. RAG 파이프라인 설계문서

2.1 전체 아키텍처



1. 입력 데이터
   :차 메타데이터 CSV · 웹 문서 · PDF 문서
2. 수집 및 전처리
   :파싱 · 정제 · 출처 기록 · 해시 계산 · 청킹
3. Collection 1 `tea_catalog`
   : 차 한 건당 하나의 메타데이터 문서

   Collection 2 `external_documents`
   : 웹·PDF 문서의 청크

4. LangGraph — retrieve
   :선택 차 메타데이터 강제 포함 · 외부 문서 검색 · 병합 · 중복 제거
5. LangGraph — generate
   :검색 근거에 기반한 답변 · 근거 번호 및 출처 유형 표시

위 구조는 구현 목표를 표현한 설계도이며, 현재 코드에서 실제로 이 구조가 동작하는지는 별도 검증이 필요하다.

2.2 Vector DB 컬렉션 설계

두 컬렉션은 저장 목적을 분리한다. 첫 번째는 차 자체의 고정적인 속성을, 두 번째는 차와 관련된 외부 문서의 상세한 설명을 저장한다.

Collection 1: `tea_catalog`

필드	자료형 예시	설명
`id`	string	차 항목의 안정적인 고유 ID
`name`	string	한글명
`english_name`	string	영문명
`category`	string	차 분류
`subcategory`	string	세부 분류
`ingredients`	string 또는 list	원료
`description`	string	설명
`caffeine_level`	boolean	카페인 함유 여부
`caffeine_mg_per_tea_amount`	number/null	제공 데이터의 카페인 수치
`tea_amount_g`	number	찻잎·원료 중량
`water_volume_ml`	number	물의 양
`water_temperature_c`	number	우림 온도
`steep_time_min`	number	우림 시간
`brewing_method`	string	제조·우림 방법
`taste`, `aroma`	string 또는 list	풍미 및 향
`source_url`	string	제공 데이터에 기록된 출처 URL

메타데이터의 각 필드는 원본 CSV에서 읽어야 한다. `id`는 원본에 고유 ID가 없으므로 정규화된 이름을 기본 키로 사용할 수 있지만, 동명이인 항목이나 이름 변경이 있을 경우 충돌 및 갱신 정책을 별도로 정의해야 한다.

검색용 텍스트는 다음과 같이 구성한다.

text

```
차 이름: 센차 (Sencha)
분류: 녹차
세부 분류: 일본 증제차
원료: 녹차 잎
설명: 증기로 산화를 억제해 제조하는 일본 녹차
카페인 함유 여부: TRUE
제공 카페인 수치: 30
원료 중량: 3g
물의 양: 200ml
물 온도: 75°C
우림 시간: 2분
우림 방법: 침출
풍미: 감칠맛, 풀향
향: 풀향, 해조향
출처 URL: https://en.wikipedia.org/wiki/Sencha
```

이 텍스트는 제공 데이터의 값을 읽어 생성하는 형식 예시이다. 카페인 수치가 검증된 측정 값이라는 의미는 아니며, 실제 색인 텍스트는 원본 필드값을 그대로 반영해야 한다.

Collection 2: `external_documents`

필드	자료형 예시	설명
`id`	string	청크 고유 ID
`document_id`	string	원문 문서 ID
`chunk_index`	integer	문서 내 청크 순번
`chunk_text`	string	청크 본문
`document_title`	string	문서 제목
`source_type`	string	`web` 또는 `pdf`
`source_url`	string/null	원문 URL
`source_file`	string/null	로컬 PDF 파일명
`page_number`	integer/null	PDF 원문 페이지
`related_tea_ids`	list	관련 차 항목 ID
`content_hash`	string	원문 또는 청크의 해시
`collected_at`	datetime	수집 일시
`license`	string/null	이용 조건 또는 라이선스 정보

웹 문서와 PDF는 같은 컬렉션에 저장하되 `source_type`과 원문 위치 메타데이터를 유지한다. 이렇게 하면 공통 임베딩 검색을 사용하면서도 답변 화면에서 출처 유형을 구별할 수 있다.

PDF의 페이지 번호는 실제 PDF 파싱 결과를 기준으로 기록하고, 웹 문서의 URL은 원문 링크를 유지한다. 확인되지 않은 라이선스는 임의로 `허용`이라고 기록하지 않고 미확인으로 남긴다.

2.3 문서 수집·청킹·색인 흐름

1. 입력 로드

   CSV를 읽고 필수 필드, 데이터 형식, 고유 항목 수를 확인한다. 외부 문서는 검색 결과 또는 제공된 파일 묶음에서 확보한다.

2. 검색어 추출 — Prompt 1

   차 이름과 사용자 질문을 바탕으로 관련 문서 검색어를 추출한다. 선택한 차의 이름과 동의어를 활용한 검색은 항상 포함한다.

3. 후보 문서 수집

   웹 검색 결과나 제공된 PDF 파일에서 후보 문서를 모은다. URL, 제목, 본문 확보 여부, 출처 유형 및 수집 상태를 기록한다.

4. 후보 선별 — Prompt 2

   제목과 요약을 바탕으로 질문과의 관련성을 평가한다. 선택된 차 자체를 다루는 문서는 일반적인 길이 제한이나 선별 규칙 때문에 제외하지 않는다.

5. 본문 추출 및 정제

   웹은 HTML에서 본문을 추출하고, PDF는 텍스트와 페이지 위치를 추출한다. 메뉴, 반복 헤더 등 불필요한 내용을 정리하되 원문 출처와 위치를 보존한다.

6. 청킹

   설정값에 따라 문서를 분할하고 청크마다 원문 문서 ID, 순번, 출처, 관련 차 ID를 부여한다.

7. 임베딩 및 색인

   메타데이터와 외부 문서를 각각의 컬렉션에 저장한다. 같은 ID의 재실행은 갱신 또는 무변경 처리하고, 내용이 변경되었을 때만 임베딩을 다시 생성한다.

8. 검증

   색인 건수, 중복 ID, 수집 실패, 청크 길이, 출처 필드를 검사하고 결과를 로그로 남긴다.

멱등 색인 정책

- 메타데이터 ID: 정규화된 항목 ID를 사용한다.
- 외부 문서 ID: 정규화된 원문 URL 또는 파일 식별자에서 생성한다.
- 청크 ID: `문서 ID + 청크 순번`을 기본으로 하며, 필요하면 관련 차 ID를 포함한다.
- 중복 수집 방지: 검색어와 문서 ID를 별도로 기록한다. 같은 검색어의 재사용 여부와 같은 URL의 중복 색인은 서로 다른 문제이므로 각각 관리한다.
- 갱신: 원문 해시가 변경되면 기존 문서의 청크를 교체하고 새 청크를 저장한다.
- 삭제: 원문에서 사라진 데이터는 명시적인 동기화 정책이 있을 때만 삭제한다.

`문서 ID + 청크 순번`은 동일 문서가 여러 차에 연결되더라도 한 문서의 청크를 공유하는 구조에 적합하다. 반대로 차별 검색 범위가 서로 달라 별도 청크가 필요한 경우에는 `차 ID + 문서 ID + 청크 순번`을 사용한다.

2.4 청크 크기, 중복 길이, Top-k 설정

초기 실험값은 다음과 같이 설정한다. 이는 프로젝트의 초기 설정 제안이며, 최적값으로 검증된 결과는 아니다.

설정	초기값	선정 이유 및 변경 영향
청크 크기	1,000자	문맥을 유지하면서 지나치게 긴 문서의 검색 집중을 줄이기 위한 시작값
중복 길이	200자	경계에 걸린 문장이 분리되어 맥락을 잃는 문제를 완화
외부 문서 Top-k	5	관련 근거를 확보하면서 생성 프롬프트에 과도한 문맥이 들어가는 것을 방지
메타데이터 근거 수	선택 항목 1건	선택한 차의 메타데이터는 검색 점수와 무관하게 항상 포함
검색 후보 수	20건	최종 근거 선정 전 후보를 넓게 확보하기 위한 초기값

청크 크기를 줄이면 세부 정보 검색이 쉬워질 수 있지만 문맥이 잘릴 가능성이 커지고 청크 수가 증가한다. 반대로 크기를 늘리면 문맥 보존에 유리하지만 서로 다른 정보가 한 청크에 섞여 검색 정밀도가 낮아질 수 있다.

중복 길이가 늘어나면 경계 문맥은 더 잘 보존되지만 유사한 내용이 여러 청크에 반복되어 저장량과 중복 검색이 증가한다.

Top-k를 늘리면 더 다양한 근거를 확보할 수 있지만, 질문과 관련성이 낮은 내용이 생성 단계에 섞일 위험도 커진다. 따라서 동일한 대표 질문에 대해 여러 설정을 비교하고 사실 정확성, 근거 적합성, 응답 시간으로 값을 결정해야 한다.

모든 설정은 코드에 고정하지 않고 `config.yaml`에서 조정할 수 있도록 한다.

2.5 검색 결과 병합 및 중복 제거

검색 단계에서는 두 컬렉션의 역할을 구분한다.

1. 사용자가 선택한 차의 메타데이터를 ID로 직접 조회한다.
2. 사용자 질문을 임베딩하여 외부 문서 컬렉션에서 의미 유사도가 높은 청크를 검색한다.
3. 메타데이터를 필수 근거로 추가한다.
4. 외부 검색 결과는 문서 ID, 청크 ID, 내용 해시를 활용해 중복을 제거한다.
5. 선택된 차와 직접 관련된 근거를 우선적으로 유지하되, 출처 유형이 다양하게 확보되도록 한다.
6. 최종 근거 목록에 번호를 부여하고 generate 노드에 전달한다.

메타데이터와 외부 문서의 ID 체계가 다르므로, 단순히 본문 텍스트만 비교하여 중복 제거하지 않는다. 동일한 문서의 청크가 여러 항목을 통해 검색되는 경우에는 원문 문서 ID와 청크 ID를 활용한다.

외부 문서의 유사도 점수와 출처별 순위는 검색 결과의 근거 선정에 사용하되, 검색 점수가 높다는 이유만으로 원문에서 확인되지 않는 주장을 사실로 취급하지 않는다.

2.6 프롬프트 설계

Prompt 1 — 외부 문서 검색어 추출

역할: 차 전문가 및 자료 조사자

목적: 사용자 질문과 선택한 차를 기반으로 외부 문서 검색어를 추출한다. 항목 자체를 다루는 문서를 검색 대상에서 누락하지 않는다.

text

```
당신은 차 종류와 차 제조·우림 정보를 조사하는 전문 자료 조사자입니다.

선택된 차의 이름, 영문명, 분류와 사용자 질문을 바탕으로
외부 문서 검색에 사용할 검색어를 생성하세요.

규칙:
1. 선택된 차 자체를 직접 다루는 검색어를 반드시 포함하세요.
2. 사용자 질문에 필요한 제조 방식, 원료, 우림 조건 등의 검색어를 추가하세요.
3. 확인되지 않은 정보를 검색어의 사실 전제로 사용하지 마세요.
4. 검색어는 중복을 제거하세요.
5. JSON 배열만 출력하세요. 설명이나 Markdown은 출력하지 마세요.
```

```
출력 형식:
["검색어 1", "검색어 2", "검색어 3"]
```

출력은 JSON 파서로 검증한다. 형식 오류가 발생하면 제한된 횟수만 재시도하고, 복구할 수 없으면 수집을 중단하거나 기본 검색어만 사용한다.

Prompt 2 — 후보 문서 선별

역할: 차 분야의 문헌 검토자

목적: 후보 문서의 제목과 요약을 평가하여 질문과 직접 관련된 문서를 선택한다.

text

```
당신은 차 관련 문헌을 검토하는 평가자입니다.

사용자 질문, 선택된 차, 후보 문서의 제목과 요약을 비교하여
답변 근거로 사용할 가치가 있는 문서를 선별하세요.

평가 기준:
- 선택된 차를 직접 다루는지
- 질문에 답하는 데 필요한 정보가 포함되어 있는지
- 출처와 문서 식별 정보가 확인되는지
- 다른 후보와 내용이 중복되는지

선택된 차 자체를 직접 다루는 문서는 일반적인 관련성·길이 제한보다
우선하여 유지해야 합니다. 다만 본문 확보 여부와 출처 확인 결과는
별도로 기록하고, 실제 수집하지 못한 문서를 수집 완료로 표시하지 마세요.

JSON 객체만 출력하세요.
문서별로 document_id, relevant, reason을 포함하세요.
```

선별 결과는 문서 수집 결과와 분리하여 저장한다. LLM이 채택했다고 해도 원문 본문을 실제로 확보하지 못했다면 색인 완료로 처리하지 않는다.

Prompt 3 — 근거 기반 답변 생성

역할: 차 정보 안내자

목적: 검색된 근거만으로 질문에 답하고, 사실을 확인할 수 없는 경우 이를 명시한다.

text

```
당신은 차 정보를 안내하는 도우미입니다.

아래 질문과 검색 근거를 이용하여 답변하세요.
```

```
규칙:
1. 제공된 근거에 포함된 내용만 사실로 서술하세요.
2. 주요 주장 뒤에 [근거 N] 형식으로 번호를 표시하세요.
3. 각 근거의 출처 유형을 구분하세요.
   - 차 메타데이터
   - 웹 문서
   - PDF 문서
4. 근거 간 내용이 충돌하면 차이를 명시하고 임의로 결론 내리지 마세요.
5. 근거에서 확인할 수 없는 정보는 확인되지 않는다고 답하세요.
6. 사용자 질문과 무관한 근거를 억지로 인용하지 마세요.
7. 카페인 수치 등 제공 데이터의 값은 검증된 사실과 구분하여
   데이터에 기록된 값으로 표현하세요.

답변은 자연스러운 한국어로 작성하세요.
사용된 근거 번호와 출처 정보는 별도의 구조화된 결과로 반환하세요.
```

실제 구현에서는 근거 텍스트와 번호를 프로그램이 명시적으로 전달하고, 답변 본문에서 인용 번호를 추출하여 실제 사용된 문서만 화면에 표시하도록 한다. 모델이 임의로 생성한 번호나 존재하지 않는 근거 ID는 무시하고 검증 오류로 기록한다.

2.7 LangGraph 구성

그래프는 요구사항에 따라 두 노드로 구성한다.

mermaid

```
flowchart TD
    A[사용자 질문 및 선택 차] --> B[retrieve]
    B --> C{메타데이터 확인}
    C -->|항상 포함| D[외부 문서 의미 검색]
    D --> E[병합 및 중복 제거]
    E --> F[generate]
    F --> G[답변 및 인용 번호 검증]
    G --> H[답변과 실제 사용 근거 표시]
```

`retrieve` 노드는 메타데이터 조회, 외부 문서 검색, 검색 결과 병합 및 중복 제거를 담당한다. `generate` 노드는 근거에 기반한 답변 생성과 인용 결과를 반환한다.

인용 번호 검증은 별도 LangGraph 노드가 아니라 generate 노드 내부의 후처리로 구현할 수 있다. 그래프의 필수 노드는 `retrieve`, `generate` 두 개로 유지한다.

권장 상태 구조

python

```
state= {"conversation_id":"...","selected_tea_id":"...","question":"...","evidence":
[],"answer":"","cited_evidence_ids": [],}
```

이 구조는 설계 예시다. 실제 타입과 상태 저장 방식은 기존 코드와 사용하는 LangGraph 버전에 맞춰 결정한다.

2.8 근거 표시 및 답변 정책

답변에는 `[근거 1]`, `[근거 2]`처럼 번호를 표시하고, 하단 근거 목록에는 실제 인용된 문서만 노출한다.

출처 유형	화면 표시 예시
차 메타데이터	`차 메타데이터 · 센차`
웹 문서	`웹 문서 · 문서 제목 · 원문 URL`
PDF 문서	`PDF 문서 · 파일명 · p.12`

위 항목은 출력 형식 예시이며, PDF 페이지 번호와 문서 제목은 실제 파싱 결과를 사용한다.

다음 상황은 별도로 처리한다.

- 검색 결과가 없으면 근거를 찾지 못했다고 안내한다.
- 답변에 인용된 근거가 없으면 근거 미인용 상태를 화면에 표시한다.
- 검색 근거가 있어도 질문에 대한 답을 뒷받침하지 못하면 확인할 수 없다고 답한다.
- 서로 충돌하는 출처가 있으면 출처별 차이를 설명한다.
- 외부 문서의 내용이 제공 메타데이터와 다르면 출처와 데이터 유형을 구분하여 제시한다.

2.9 도메인 특화 기능 설계

Tea Lab의 특화 기능은 우림 조건 안내 및 조건별 차 탐색으로 설계한다.

기능	입력	처리	출력
우림 조건 안내	차 선택 또는 차 이름	메타데이터 검색 및 관련 문서 조회	물 온도, 원료량, 물의 양, 우림 시간
카페인 기준 탐색	카페인 관련 자연어 조건	제공된 카페인 필드와 근거 확인	조건에 맞는 차 후보
풍미 기반 탐색	고소함, 꽃향 등 자연어 조건	풍미·향 필드 검색 및 후보 검토	조건에 맞는 차 목록

기능	입력	처리	출력
차 비교	두 종류 이상의 차 선택	메타데이터 및 외부 근거 병합	공통점과 차이점, 출처

카페인 수치는 제공 데이터의 기록값과 외부 출처에서 확인한 값을 구분한다. 원문에서 검증되지 않은 함량을 확정적으로 설명하지 않으며, 단순한 카페인 포함 여부를 실제 음용 시의 정확한 섭취량과 동일하게 취급하지 않는다.

2.10 설계 선택의 이유와 예상 문제

설계 선택	이유	예상 문제 및 대응
두 컬렉션 분리	구조화된 차 속성과 긴 외부 문서를 독립적으로 관리	서로 다른 ID 체계가 필요하므로 출처 유형과 고유 ID를 명시
차 메타데이터 강제 포함	선택한 차에 대한 기본 정보 누락 방지	질문과 무관한 필드는 답변 근거로 과도하게 사용하지 않도록 제한
청크 단위 검색	질문에 관련된 문맥을 선택적으로 전달	청크 경계로 정보가 잘릴 수 있어 중복 길이를 설정으로 관리
검색어·문서 캐시	불필요한 외부 호출과 중복 색인 방지	문서 내용이 변경되었는지 해시로 확인
웹·PDF 통합 컬렉션	출처 유형과 관계없이 공통 검색 흐름 사용	PDF 파싱 실패와 페이지 정보 누락을 별도로 기록
LangGraph 2노드	검색과 생성을 분리하여 기능 및 테스트 범위를 명확히 함	검색 실패 시 생성 단계에 빈 근거를 전달하지 않도록 예외 처리
인용 번호 후처리	실제 사용된 근거만 화면에 표시	존재하지 않는 인용 번호는 검증 오류로 처리

이 표의 문제점은 설계 단계에서 예상되는 항목이다. 실제 구현 과정에서 발생한 문제와 해결 과정은 실행 로그, 코드 변경 내역 및 테스트 결과를 근거로 추가해야 한다.